

GAN

GAN

数学原理:

原数据:

$$P_{data}$$

生成的概率分布(Generator生成):

$$P_g(x : \theta_g)$$

噪声分布 (比较简单的分布) :

$$P_z$$

过程简述:

从噪声分布中选取点, 进入GNN学习 (generator) , 输入 z (分布中的点) , 通过学习输出

$$output = G(z : \theta_g) \text{ 中的样本}$$

ps: $P_g = G(z : \theta_g)$

再将输出的 x (生成器的结果) 和从 P_{data} 中选取的 x (样本--真品) 送入另一个GNN (鉴别器) 训练。

判断鉴别器的鉴别水平?

能够鉴别生成图片的真假: $D(x)$ 表示图片为真的概率, 这个GNN的训练目标是: GNN使得假输入 $D(x)$ 低, 真输入高。

if x comes from P_{data} , $D(x)$ 大, $\log D(x)$ 也大

if x comes from P_z , $D(x)$ 小, 这里 x 是来自generator产生分布的

样本, 所以也就是可以用 $output$ 代替, $D(output)$ 小, $D(G(z : \theta_g))$ 小, $\log(G(z : \theta_g))$ 小, $1 - \log(G(z : \theta_g))$ 要大。

目标为: $\max_D E_{x \sim P_{data}} \log D(x) + E_{z \sim P_z} \log[1 - G(z : \theta_g)]$

判断生成器生成水平?

if x comes from P_g , $D(x)$ 大, (生成水平高让鉴别器误以为真实)
这里 x 是来自 generator, 所以也就是可以用 $output$ 代替, $D(output)$ 大, $D(G(z : \theta_g))$ 大, $\log(D(z : \theta_g))$ 大, $\log[1 - G(z : \theta_g)]$ 小。

目标: $\min_G E_{z \sim P_z} \log[1 - G(z : \theta_g)]$

综上目标函数:

$$\min_G \max_D E_{x \sim P_{data}} \log D(x) + E_{z \sim P_z} \log(1 - G(z : \theta_g))$$



GAN优化

discriminator :

伯努利分布 (二项分布)

目标函数存在最优解吗?

存在最优解, 要能证明 $P_g == P_{data}$?

证明 存在最优解时, $P_g == P_{data}$ (简做 P_d)

假设 G 不动。

$$V(D, G) = E_{x \sim P_d} \log D(x) + E_{x \sim P_g} (\log(1 - D(x)))$$

求 $\max_D V(G, D)$

$$\begin{aligned} V(G, D) &= \int P_d * \log D(x) dx + \int P_g * \log[1 - D(x)] dx \\ &= \int (P_d * \log D(x) + P_g * \log[1 - D(x)]) dx \\ &= \int_0^1 (P_d * \log D + P_g * \log[1 - D]) dD \end{aligned}$$

(注解：看上去D与x是相关的，输入一个x，输出一个D(x)，但是将x看作开区间，x可以取实数任何值，但是它们对D映射的值一定在0到1之间)

如果要求 $V(G, D)$ 最大，那么它对D的导数就应该是0；

$$\begin{aligned}\frac{\partial V(G, D)}{\partial D} &= 0 \\ \frac{\partial V(G, D)}{\partial D} &= \int \frac{\partial (P_d * \log D(x) + P_g * \log [1 - D(x)])}{\partial D} = 0 \quad \text{积分与微分可以交换计算} \\ P_d * \frac{1}{D} + P_g * \frac{-1}{1-D} &= 0 \\ P_d * \frac{1}{D} &= P_g * \frac{1}{1-D} \\ D_G^* &= \frac{P_d}{P_d + P_g}\end{aligned}$$

现在D已经求出，回代到方程。

$$\min_G V(G, D_G^*) = E_{x \sim P_d} \log \frac{P_d}{P_d + P_g} + E_{x \sim P_g} \log \frac{P_g}{P_g + P_d}$$

观察上述算式，发现类似于kl divergence

但是 $p_d + p_g$ 不是分布，因为当 $p_d = 1, p_g = 1$ 的时候， $p_d + p_g$ 就等于2，明显不是分布。

凑出kl divergence

$$\begin{aligned}\min_G V(G, D_G^*) &= E_{x \sim P_d} \log \left[\frac{P_d}{\frac{P_d + P_g}{2}} * \frac{1}{2} \right] + E_{x \sim P_g} \log \left[\frac{P_g}{\frac{P_d + P_g}{2}} * \frac{1}{2} \right] \\ &= D_{KL}(P_d || \frac{P_d + P_g}{2}) + D_{KL}(P_g || \frac{P_d + P_g}{2}) - \log 4 \geq -\log 4\end{aligned}$$

当 $P_d = P_g = \frac{P_d + P_g}{2}$ 时，“=”成立

目标函数变成最小， $D_G^* = \frac{1}{2}$

kl divergence 是啥(相对熵)

量化两种概率分布P和Q之间差异的方式

分布的熵

信息量： $-\log p$ --p:一件事发生的概率

熵：信息量对概率分布的期望；

$$E_{x \sim p(x)} [-\log p] = \int -p(x) * \log p(x)$$

$$H = - \sum_{i=1}^N p(x_i) * \log p(x_i)$$

KL divergence定义:

$$D_{KL}(p||q) = \sum_{i=1}^N p(x_i) * (\log p(x_i) - \log q(x_i))$$

$$D_{KL}(p||q) = \sum_{i=1}^N p(x_i) * \log \frac{p(x_i)}{q(x_i)}$$

***K-L散度其实是数据的原始分布p和近似分布q之间的对数差值的期望**

KL可以看出不同分布之间的差距（不是距离）用q近似p造成的误差